

Máscaras para imágenes de Skipper-CCD que no dependen del sensor

¿Se pueden escribir las máscaras que descartan defectos de lectura, defectos del material y física no buscada de modo que funcionen en un sensor para el que nunca fueron ajustadas?

D. Rodríguez Juiz y F. Pérez · trabajo final, *Ondas Gravitacionales e Investigación Asistida por IA* · informe completo, código y procedencia: <https://delfinarj.github.io/GW-AI-final-project/>

Respuesta corta. Sí para cinco de las seis máscaras, y el precio se puede medir. De los 28 casos en que una máscara ajustada a mano en un sensor se trasladó sin cambios a otro, 5 fueron peores que no enmascarar nada en todas las semillas y 2 no cambiaron nada; el más claro, clusters de baja energía en el sensor de superficie (ajustada en subterráneo profundo), obtiene 0.12 de lo que obtiene la máscara ajustada con la verdad en ese mismo sensor, donde no hacer nada obtiene 1.00. Las mismas máscaras escritas como procedimientos que se calibran solos son peores que no enmascarar en 1 de 14 casos y mejores en 12, y alcanzan una mediana de 0.98 de la máscara ajustada con la verdad. La excepción es clusters de baja energía en el sensor de superficie (adaptativa), que dispara sobre electrones de las estelas de transferencia de carga.

La pregunta y qué se construyó

Un Skipper-CCD cuenta electrones de a uno. Antes de extraer cualquier física, los análisis descartan píxeles con máscaras, cada una apuntada a un problema: carga que queda atrás durante la transferencia, impactos en el registro serie, columnas y píxeles calientes, fotones alrededor de trazas de alta energía (el halo), clusters de eventos de baja energía y trazas de muones. Cada máscara lleva tamaños y umbrales — un radio, un largo de estela, un corte en tasa — elegidos a mano para un sensor y un sitio.


Hipótesis: lo que se transfiere entre sensores no son los números sino el *procedimiento* que los elige. Por eso cada una de las seis máscaras se escribió dos veces: una forma **fija**, con constantes puestas a mano, y una forma **adaptativa**, que mide sus propios tamaños sobre las imágenes a las que se aplica y fija su umbral con una tasa de falsos positivos ($\alpha = 0.01$, corregida por el número de tests) o con propiedades físicas medibles del sensor.

El banco de pruebas es un simulador que guarda un mapa de carga separado por fuente, de modo que una máscara se puede puntuar contra exactamente los eventos que debería remover. Tres sensores difieren como difieren los despliegues reales; su geometría, ruido, tasas de corriente oscura, fondos y flujos de muones salen de mediciones públicas, mientras que las poblaciones de defectos, que no se publican de forma transferible, son valores de escenario elegidos para diferir entre sensores.

Sensor	Píxeles	Espesor (μm)	Ruido (e ⁻)	Exposición	Oscura (e ⁻ /pix/día)	Muones (cm ⁻² /día)
Subterráneo profundo	3072×512	665	0.14	20 h	1.4×10 ⁻⁵	2.9e-05
Subterráneo somero	3072×443	675	0.14	20 h	1.6×10 ⁻⁴	6.9
Laboratorio en superficie	1278×1058	725	0.17	1 h	3.0×10 ⁻²	1.4e+03

De cada máscara se compararon cuatro formas sobre una pila de prueba independiente de cada sensor: el **oráculo** (la forma fija ajustada con la verdad del simulador en ese sensor), el **trasplante** (las constantes del oráculo de otro sensor), la forma **adaptativa** y **ninguna máscara**. La figura de mérito es $S/\sqrt{S+B}$: señal inyectada que sobrevive contra fondo buscado que sobrevive.

Resultado 1 · Trasplantar constantes puede hacer daño; calibrarse solo evita los desastres, pero cuesta



Cada máscara en cada sensor, relativa al oráculo de ese sensor, sobre 5 semillas. Una máscara trasplantada es el oráculo de otro sensor. La línea punteada en 1 es ese oráculo, que queda ahí porque es el divisor; la barra gris es «ninguna máscara», y esa es la comparación que decide si enmascarar sirve de algo.


Mover constantes entre sensores no es apenas subóptimo: puede ser peor que no enmascarar. 5 de 28 trasplantes puntúan por debajo de no enmascarar en todas las semillas, por más del 1 % de margen que se usa para llamar real a una diferencia. La autocalibración elimina esos desastres — 1 de 14 casos — pero no sale gratis: en 8 casos un trasplante le sigue ganando a la adaptativa en todas las semillas, y el peor caso adaptativo, estelas de transferencia de carga en el sensor de superficie (adaptativa), llega sólo a 0.38 del oráculo (0.34 en su peor semilla).

Los estadísticos del resumen se registraron antes de la corrida final. Los casos con menos de 20 eventos buscados en una semilla quedan excluidos de esa semilla, y un caso cuenta como dañino sólo si pierde por más del margen en *todas* las semillas válidas. Dos semillas (2) se corrieron una sola vez después de congelar el código y nunca se usaron para cambiar nada: en ellas, 4 de 26 trasplantes son dañinos, 0 de 13 casos adaptativos lo son, y la mediana adaptativa es 0.98 del oráculo — el mismo cuadro que en las semillas de desarrollo.

Resultado 2 · Sobre qué disparan las máscaras cuando no hay nada que encontrar

Con todos los defectos apagados en los tres sensores, y dejando lo que un sensor real no puede apagar (corriente oscura, carga espuria, la señal inyectada, trazas de muones y depósitos de alta energía), las cinco máscaras estadísticas dispararon 5 veces en 15 tests de sensor y máscara de 50 corridas cada uno, y todos los intervalos contienen α . La sexta máscara, la de muones, no puede estar en ese test, porque las trazas son justamente lo que un sensor real no puede apagar; preguntado aparte, en un simulador con el flujo en cero, disparó en 0 de 600 imágenes.

Ese test tiene un punto ciego: apagar todos los defectos a la vez no puede ver una máscara disparando sobre el defecto *de otra*. Así que los defectos también se encendieron de a uno, 60 celdas de máscara y defecto en total, 20 corridas cada una, con el límite que cada celda debe superar tomado al 99.92 % de confianza para controlar un 5 % de probabilidad de una falsa alarma en toda la grilla.



Un defecto encendido por vez. El área del punto es la fracción de ensayos en que la máscara disparó; el naranja marca las celdas por encima de la tasa que esa máscara no debería superar; los círculos huecos son la diagonal, donde una máscara se encuentra con su propio defecto.

7 de 60 celdas disparan sobre un defecto que no es el suyo — y las 6 contadas por imagen sobreviven a recontarlas de a una corrida, que es la forma conservadora de tratar dos imágenes que comparten una calibración. Las estelas de transferencia de carga son lo que más veces las enciende. La mayor no deja lugar a dudas: en el sensor de superficie, con las estelas como único defecto presente, la máscara adaptativa de clusters de baja energía dispara en todos sus ensayos y enmascara una mediana de 0.121 de la imagen. Es la única falla real de la autocalibración encontrada acá, y estaba predicha por escrito antes de la corrida, a partir de un síntoma visto en el Resultado 1.

Sensor	Único defecto presente	Máscara que disparó	Disparos/ensayos	Tasa	Fracción mediana enmascarada
Laboratorio en superficie	estelas de transferencia de carga	clusters de baja energía	40/40	1.00	0.1215
Laboratorio en superficie	estelas de transferencia de carga	impactos en el registro serie	34/40	0.85	0.0009
Subterráneo somero	estelas de transferencia de carga	clusters de baja energía	19/40	0.47	0.0000
Laboratorio en superficie	estelas de transferencia de carga	columnas y píxeles calientes	9/20	0.45	0.0000
Subterráneo somero	halo	clusters de baja energía	10/40	0.25	0.0000
Subterráneo somero	clusters de baja energía	impactos en el registro serie	6/40	0.15	0.0000
Subterráneo somero	estelas de transferencia de carga	impactos en el registro serie	5/40	0.12	0.0000

Resultado 3 · Los mismos procedimientos sobre un sensor real

Todo lo anterior es simulado. Las máscaras adaptativas también se corrieron, sin cambiarles nada, sobre las 4 exposiciones del release público de SENSEI en SNOLAB: un cuarto sensor, real, con una geometría que ningún preset tiene (3072×16 superpíxeles activos, cada uno binando 32 filas físicas). No se ajustó nada para él, y el release publica su propia máscara, así que las dos se pueden comparar donde se superponen.

Con sólo las imágenes, el estimador mide un ruido de lectura de 0.141–0.142 e, contra 0.1413–0.1420 e de un ajuste independiente sobre los mismos archivos, y una densidad de un electrón que crece con la exposición. El procedimiento de columnas calientes marca 2, 4, 6, 7 columnas a medida que crece la exposición, y los conjuntos están anidados: cada uno conserva las anteriores y agrega la siguiente más ruidosa. En la exposición más larga, las 7 columnas con mayor tasa de píxeles cargados son exactamente las que marca, todas dentro de la máscara de columnas malas del propio release, y cada una carga entre 102 y 1830 veces la tasa de píxeles cargados de las columnas que dejó en paz.

Exposición	Imágenes	Píxeles disparadores	Ruido (e ⁻)	Densidad 1e	Columnas calientes	Radio de halo	Enmascaramos	Enmascara el release
0 h	14	0	0.142	1.3×10 ⁻⁴	2	0	0.0007	0.042
2 h	14	70	0.142	1.7×10 ⁻⁴	4	0	0.0013	0.055
6 h	14	103	0.141	2.9×10 ⁻⁴	6	0	0.0038	0.061
20 h	13	844	0.141	6.5×10 ⁻⁴	7	25	0.0094	0.130

Las dos direcciones del acuerdo dicen cosas distintas y las dos están acá. De lo que el procedimiento marca, el release también marca 0.99–1.00: se queda adentro de una máscara que ajustó una persona. De lo que marca el release, el procedimiento marca 0.027–0.095: el release enmascara mucho más. El primer número es la dirección fácil — un procedimiento que marcara una sola columna verdadera sacaría 1.00 — y se apoya en un puñado de decisiones por columna, no en los cientos de píxeles sobre los que se cuenta.

La calibración de estelas eligió largo cero en las cuatro exposiciones, algo que la expectativa registrada no predijo. El motivo está en el archivo de resultados: el release oculta sus impactos, así que una exposición entera tiene 0, 70, 103, 844 píxeles por encima del disparador. En la exposición más larga el test sí ve el exceso del lado correcto — 13 electrones simples río abajo de un disparador contra 2 río arriba, $p = 0.0037$ — pero el umbral corregido pide $p < 6.3 \times 10^{-5}$. El procedimiento se niega a enmascarar con evidencia tan flaca, que es para lo que fue construido.

Cómo se hizo el trabajo, y cómo se verificó

Cada línea de código y cada análisis de este proyecto los produjeron agentes de IA, a partir de una pregunta explícita y bajo reglas escritas antes de empezar: ningún número de ninguna página se escribe a mano, cada salida lleva un sidecar con el script, el commit de git, los hashes de sus entradas y su semilla, y ningún documento privado entra jamás en un archivo versionado. Lo que hizo esto confiable, y no solamente rápido, fue el método adversarial:

- **Las expectativas se registraron antes de correr.** Escritas en `PLAN.md` y commiteadas antes de que el análisis corriera, para que una confirmación no se pudiera inventar después. Una de ellas estuvo equivocada — el largo de estela en el sensor real — y el repositorio lo dice, con los números que lo explican.
- **Agentes independientes revisaron el trabajo** sin acceso a la conversación que lo produjo. Encontraron defectos reales: verdad del simulador filtrándose en un umbral «adaptativo»; un titular que medía no hacer nada; una máscara de halo midiendo distancias en superpíxeles sobre un sensor binado, que escondía la columna más ruidosa de la calibración de columnas calientes; un veredicto aplicado a sesenta celdas sin corregir por su número. Cada uno está en `PROVENANCE.md` con lo que se hizo al respecto, incluidos los hallazgos que *no* se corrigieron.
- **Todos los resultados se reprodujeron desde un clon limpio** — un checkout nuevo que no comparte nada con la copia de trabajo salvo el commit y el entorno fijado — y se compararon con una tolerancia relativa de 10^{-9} . Todos volvieron idénticos, figuras incluidas. El más lento, de dos horas y media, hubo que retomarlo después de que algo lo matara por la mitad, y eso fue lo que mostró que el comando que un desconocido correría para reproducirlo no hacía nada en un clon limpio: encontraba el archivo terminado que publicamos y se salteaba el trabajo.

Los errores que atraparon las verificaciones están listados en la página del informe completo, no escondidos: un simulador que volvía a sortear sus columnas calientes en cada imagen, una máscara de columnas calientes que marcaba vecinas inocentes, un test de halo que trataba su tasa de referencia como exacta, una máscara de muones que perdía las trazas cruzadas, y un orden de calibración que hacía falsas 69 de 81 columnas marcadas.

Qué sigue mal

- Las poblaciones de defectos son valores de escenario, no mediciones; sólo los parámetros del sensor y de los fondos son mediciones públicas.
- Los defectos se encienden de a uno, así que nada de esto mide qué hacen las máscaras cuando varios defectos se superponen en los mismos píxeles.
- En el sensor real sólo cuatro de las seis máscaras se pueden verificar: el release no publica contraparte de la máscara de clusters de baja energía, y sus superpíxeles binados hacen que la geometría de la máscara de muones no tenga sentido.
- Una sola figura de mérito, y un oráculo ajustado máscara por máscara y no en conjunto, así que una máscara adaptativa combinada puede superarlo.

Dónde está todo

Repositorio: <https://github.com/delfinarj/GW-AI-final-project> — `README.md` reproduce el proyecto entero desde un clon limpio con `uv`; `PLAN.md` tiene las afirmaciones registradas de antemano; `PROVENANCE.md` registra cada entrada, cada elección que tenía una alternativa defendible, cómo se verificó cada resultado y cada error encontrado en el camino; `report/index.html` es el informe completo, del que este documento es un resumen.